

PROJETO DE PORTFÓLIO — ANÁLISE DE DADOS

Brazilian E-Commerce Analytics

Dataset Olist

Preparação, Validação, Qualidade, Análise de Negócio e Dashboard
com PostgreSQL, SQL, Power Query, DAX e Power BI

Renato Marcondes de Souza

[linkedin.com/in/renato-m-souza](https://www.linkedin.com/in/renato-m-souza)

2026

Sumário

1. Visão geral do projeto	3
1.1 Objetivos	3
1.2 Tecnologias	3
1.3 Repositório do Projeto	3
2. Dataset e estrutura dos dados	4
2.1 Tabelas Criadas no PostgreSQL	4
2.2 Relacionamento entre Tabelas	5
3. Data Validation	5
3.1 Etapa 1 — Volume	5
3.2 Etapa 2 — Duplicidades	6
3.3 Etapa 3 — Valores Nulos	7
3.4 Etapa 4 — Integridade Referencial	9
4. Data Quality	9
5. Resumo Consolidado	15
6. Guia de Tratamento para Modelagem	16
7. Business Analysis	16
7.1 Visão geral comercial e comportamento de compra	17
7.2 Tendências de vendas	17
7.3 Produtos e categorias	18
7.4 Clientes e distribuição geográfica	18
7.5 Logística e cumprimento de prazo	19
7.6 Logística e satisfação do cliente	19
7.7 Principais insights de negócio	20
8. Dashboard no Power BI	20
8.1 Modelagem analítica e critérios de cálculo	20
8.2 Estrutura do dashboard	20
8.3 Página 1 — Visão Geral	21
8.4 Página 2 — Vendas & Produtos	22
8.5 Página 3 — Logística & Satisfação	23
8.6 Validação dos KPIs entre SQL e Power BI	24
9. Considerações Finais	24

1. Visão geral do projeto

RESUMO EXECUTIVO

- Dataset: ~100 mil pedidos de e-commerce (Olist/Kaggle), 9 tabelas, mais de 1,5 milhão de registros, carregados em PostgreSQL.
- Processo aplicado: Data Validation (4 etapas) + Data Quality (8 regras) + Business Analysis em 6 frentes + modelagem analítica, medidas DAX e dashboard em Power BI.
- Principais resultados: 0 duplicidades nas 8 tabelas com chave definida, 0 registros órfãos nas relações principais e 99,69% de consistência financeira; 96.478 pedidos delivered, 93.358 clientes únicos com pedidos entregues, Product GMV de R\$ 13,22 mi, AOV de R\$ 159,83 e On-Time Delivery Rate de 93,23%.
- Projeto concluído com dashboard em 3 páginas no Power BI. Visão Geral, Vendas & Produtos, Logística & Satisfação.

Este projeto analisa o conjunto de dados que foi disponibilizado publicamente pela Olist (olist.com) no Kaggle, plataforma voltada para Data Science, Data Analytics e Machine Learning. O objetivo é construir uma análise de e-commerce de ponta a ponta, partindo da compreensão e preparação dos dados até a criação de indicadores, insights de negócio e um dashboard em Power BI.

O dataset contém dados de aproximadamente 100 mil pedidos de e-commerce no Brasil, e contém informações sobre clientes, pedidos, itens, produtos, vendedores, pagamentos, avaliações e localização. O período dos pedidos vai de 04/09/2016 a 17/10/2018.

Fonte: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce?resource=download>

Fluxo do projeto:

Dados brutos → Entendimento → PostgreSQL/SQL → Data Validation → Data Quality → Análise de negócio → Power BI

1.1 Objetivos

- Validar a carga e a estrutura do conjunto de dados.
- Avaliar completude, duplicidades, integridade referencial e consistência das principais regras de negócio.
- Definir critérios seguros para utilização dos dados em indicadores financeiros, logísticos e de satisfação.
- Responder perguntas de negócio e transformar os resultados em dashboard no Power BI.

1.2 Tecnologias

Tecnologia	Uso no projeto
PostgreSQL	Armazenamento e modelagem relacional
SQL	Validação, transformação e análise
Power BI	Power Query, modelagem analítica, DAX, KPIs e dashboard
GitHub	Versionamento e apresentação do portfólio

1.3 Repositório do Projeto

Todo o código SQL desenvolvido ao longo do projeto, além do arquivo Power BI (.pbix) com a modelagem, as medidas DAX e o dashboard final, está versionado publicamente no GitHub, organizado por etapas para facilitar a consulta, a reprodução das análises e a evolução do projeto.

A documentação apresenta apenas consultas SQL representativas da metodologia utilizada. O conjunto completo de scripts, incluindo criação das tabelas, validações de qualidade, análises de negócio e consultas utilizadas na construção dos indicadores, é mantido no repositório.

Repositório: <https://github.com/RenatoMarcondes/olist-ecommerce-analytics>

Estrutura de pastas:

```
olist-ecommerce-analytics/
|-- sql/
|   |-- 01_schema.sql
|   |-- 02_data_validation.sql
|   |-- 03_data_quality.sql
|   `-- 04_business_analysis.sql
|-- dashboard/
|   |-- olist_dashboard.pbix
|   `-- images/
|       |-- Dashboard01_visaogeral.png
|       |-- Dashboard02_vendaseprodutos.png
|       `-- Dashboard03_logisticaesatisfacao.png
|-- docs/
|   `-- Projeto_Olist_Analytics.docx
`-- README.md
```

2. Dataset e estrutura dos dados

A Olist conecta vendedores a consumidores em um marketplace. Após a compra, o pedido percorre etapas de aprovação, envio e entrega; posteriormente, o cliente pode registrar uma avaliação. Essa estrutura permite analisar vendas, logística, comportamento de pagamento, satisfação e distribuição geográfica.

As 9 tabelas do dataset foram recriadas no PostgreSQL com tipos de dados, chaves primárias e restrições NOT NULL definidas a partir do entendimento prévio de cada campo, antes da importação dos arquivos .csv.

Banco de dados: olist_analytics

Tabela	Registros	Colunas	Descrição
orders	99.441	8	Pedidos, status e datas do ciclo do pedido
order_items	112.650	7	Itens, preços, frete, produtos e vendedores
order_payments	103.886	5	Formas, parcelas e valores de pagamento
order_reviews	99.224	7	Notas e comentários dos clientes
customers	99.441	5	Identificação e localização dos clientes
products	32.951	9	Categorias e atributos físicos dos produtos
sellers	3.095	4	Identificação e localização dos vendedores
geolocation	1.000.163	5	Prefixos de CEP e coordenadas geográficas
category_translation	71	2	Tradução das categorias para inglês

Total: mais de 1,5 milhão de registros distribuídos pelas 9 tabelas. Período de 04/09/2016 a 17/10/2018.


2.1 Tabelas Criadas no PostgreSQL

O script completo de criação das 9 tabelas (DDL) está disponível em: [sql/01_schema.sql](#)

Tabela	Chave Primária	Arquivo .csv importado
orders	order_id	olist_orders_dataset.csv
order_items	order_id + order_item_id	olist_order_items_dataset.csv
order_payments	order_id + payment_sequential	olist_order_payments_dataset.csv
order_reviews	review_id + order_id	olist_order_reviews_dataset.csv
customers	customer_id	olist_customers_dataset.csv
products	product_id	olist_products_dataset.csv
sellers	seller_id	olist_sellers_dataset.csv
geolocation	sem PK definida	olist_geolocation_dataset.csv
category_translation	product_category_name	product_category_name_translation.csv

2.2 Relacionamento entre Tabelas

Estrutura dos relacionamentos lógicos entre as tabelas:



A associação de customers e sellers com geolocation é realizada pelo prefixo de CEP (zip_code_prefix). Como esse campo não é único na tabela geolocation, essa relação não é uma chave estrangeira convencional (N : 1); ela requer agregação ou deduplicação antes de ser utilizada na camada analítica.

3. Data Validation

Nesta etapa, foram realizadas validações estruturais e de completude com o objetivo de verificar se os dados foram importados corretamente e se apresentam condições adequadas para as análises posteriores. Foram avaliados o volume de registros das tabelas, a existência de duplicidades, a presença de valores nulos e a integridade referencial entre as principais entidades do dataset.

Estas validações correspondem às dimensões de completude, unicidade e validade estrutural dos dados.

O processo de validação seguiu um checklist em quatro etapas:

Etapa	Objetivo
1	Volume — confirmar que todas as tabelas foram importadas corretamente
2	Duplicidades — garantir que a chave única de cada tabela não está repetida indevidamente
3	Valores nulos — identificar campos com NULL e avaliar se são esperados pela regra de negócio
4	Integridade referencial — identificar registros “órfãos” entre tabelas relacionadas

O script completo das validações: [sql/02_data_validation.sql](#)

3.1 Etapa 1 — Volume

Objetivo: confirmar que todas as tabelas foram importadas corretamente e entender o volume de dados.

```
SELECT 'customers' AS tabela, COUNT(*) AS registros FROM customers
UNION ALL SELECT 'orders', COUNT(*) FROM orders
UNION ALL SELECT 'order_items', COUNT(*) FROM order_items
UNION ALL SELECT 'order_payments', COUNT(*) FROM order_payments
UNION ALL SELECT 'order_reviews', COUNT(*) FROM order_reviews
UNION ALL SELECT 'products', COUNT(*) FROM products
UNION ALL SELECT 'sellers', COUNT(*) FROM sellers
UNION ALL SELECT 'geolocation', COUNT(*) FROM geolocation
UNION ALL SELECT 'category_translation', COUNT(*) FROM category_translation
ORDER BY tabela;
```

Tabela	Registros
customers	99.441
orders	99.441
order_items	112.650
order_payments	103.886
order_reviews	99.224
products	32.951
sellers	3.095
geolocation	1.000.163
category_translation	71

Conclusão: a validação confirmou que as 9 tabelas foram importadas corretamente para o PostgreSQL, totalizando mais de 1,5 milhão de registros, em linha com a estrutura esperada do dataset (aproximadamente 99 mil pedidos, 112 mil itens e mais de 1 milhão de registros de geolocalização).

3.2 Etapa 2 — Duplicidades

Objetivo: identificar registros duplicados que possam comprometer a análise ou seja, garantir que a chave que identifica unicamente um registro não esteja repetida de forma indevida.

Observação: nem toda repetição de um ID é duplicidade. O primeiro passo foi identificar, para cada tabela, qual é a chave que deveria ser única — algumas tabelas têm chave simples, outras têm chave composta.

Padrão de verificação aplicado a todas as tabelas (exemplo com a tabela orders):

```
SELECT order_id, COUNT(*) AS quantidade
FROM orders
GROUP BY order_id
HAVING COUNT(*) > 1;
```

O mesmo padrão foi aplicado a cada tabela, ajustando a chave para as tabelas com chave composta.

Tabela	Chave analisada	Resultado
orders	order_id	0 duplicidades
customers	customer_id	0 duplicidades
products	product_id	0 duplicidades
sellers	seller_id	0 duplicidades
order_items	order_id + order_item_id	0 duplicidades
order_payments	order_id + payment_sequential	0 duplicidades
order_reviews	review_id + order_id	0 duplicidades
category_translation	product_category_name	0 duplicidades
geolocation	linha completa	registros repetidos identificados

Conclusão: a análise de duplicidades não identificou registros duplicados nas principais tabelas transacionais e cadastrais quando consideradas suas respectivas chaves únicas. As tabelas **orders**, **customers**, **products**, **sellers**, **order_items**, **order_payments**, **order_reviews** e **category_translation** apresentaram consistência nas chaves analisadas.

Na tabela **geolocation**, entretanto, foram identificados registros exatamente iguais. Essa ocorrência não representa duplicidade de clientes ou pedidos, pois a tabela contém informações geográficas associadas a prefixos de CEP e pode apresentar múltiplas ocorrências para uma mesma região. Por esse motivo, nenhum registro será excluído da base original nesta etapa. Caso a tabela seja utilizada posteriormente em relacionamentos ou análises geográficas, poderá ser criada uma versão deduplicada para evitar duplicação de registros e distorções nas agregações.

3.3 Etapa 3 — Valores Nulos

Objetivo: identificar quais campos possuem valores NULL e, principalmente, entender se esses valores representam um problema ou se são esperados dentro da regra de negócio.

O mesmo padrão de verificação (COUNT(*) total vs. COUNT(coluna) por campo) foi aplicado a todas as tabelas. (exemplo com a tabela sellers):

```
SELECT
  COUNT(*) AS total_registros,
  COUNT(seller_id) AS seller_id_preenchido,
  COUNT(seller_zip_code_prefix) AS zip_preenchido,
  COUNT(seller_city) AS cidade_preenchida,
  COUNT(seller_state) AS estado_preenchido
FROM sellers;
```

Tabela	Principal resultado	Decisão
customers	Sem valores nulos	Sem tratamento
sellers	Sem valores nulos	Sem tratamento
order_items	Sem valores nulos	Sem tratamento
order_payments	Sem valores nulos	Sem tratamento
geolocation	Sem valores nulos	Sem tratamento
category_translation	Sem valores nulos	Sem tratamento
products	610 sem categoria/atributos descritivos; 2 sem peso/dimensões	Manter e considerar em análises específicas
order_reviews	87.656 sem título; 58.247 sem comentário	Campos opcionais; review_score permanece utilizável
orders	160 sem aprovação; 1.783 sem envio; 2.965 sem entrega	Interpretar em conjunto com order_status

products

Campo	Preenchidos	Nulos
product_id	32.951	0
product_category_name	32.341	610
product_name_lenght	32.341	610
product_description_lenght	32.341	610
product_photos_qty	32.341	610
product_weight_g	32.949	2
product_length_cm / height_cm / width_cm	32.949	2

Nenhum produto está sem **product_id** chave usada para relacionar produtos a **order_items**. Os 610 produtos sem categoria (e sem atributos descritivos) foram mantidos, pois continuam sendo produtos válidos e podem estar relacionados a pedidos; a ausência de categoria deve ser considerada nas análises por categoria. Os 2 produtos sem peso/dimensões (~0,006% da tabela) têm impacto mínimo, mas foram registrados como questão de qualidade.

order_reviews

Campo	Preenchidos	Nulos
review_id / order_id / review_score	99.224	0
review_comment_title	11.568	87.656
review_comment_message	40.977	58.247
review_creation_date / review_answer_timestamp	99.224	0

Os campos estruturais estão 100% preenchidos. Título e comentário são opcionais e sua ausência não caracteriza problema de qualidade; as avaliações continuam válidas para análises de satisfação baseadas na nota **review_score**.

orders

Campo	Preenchidos	Nulos
order_id / customer_id / order_status / purchase_timestamp	99.441	0
order_approved_at	99.281	160
order_delivered_carrier_date	97.658	1.783
order_delivered_customer_date	96.476	2.965
order_estimated_delivery_date	99.441	0

Os campos principais (identificação, status, data da compra e previsão de entrega) estão completos. Os nulos aparecem nas datas de processamento e entrega. Isoladamente isso não é erro; foi necessário relacionar cada nulo ao status do pedido:

```
SELECT order_status, COUNT(*) AS total_pedidos,
       COUNT(order_approved_at) AS aprovacao_preenchida,
       COUNT(order_delivered_carrier_date) AS envio_preenchido,
       COUNT(order_delivered_customer_date) AS entrega_preenchida
FROM orders
GROUP BY order_status
ORDER BY total_pedidos DESC;
```

Status	Total	Aprovação	Envio	Entrega
delivered	96.478	96.464	96.476	96.470
shipped	1.107	1.107	1.107	0
canceled	625	484	75	6
unavailable	609	609	0	0
invoiced	314	314	0	0
processing	301	301	0	0
created	5	0	0	0
approved	2	2	0	0

A maior parte dos nulos é coerente com o fluxo do pedido:

shipped/processing/invoiced/approved/created/unavailable ainda não chegaram (ou não chegarão) às etapas posteriores — esperado.

delivered, no entanto, deveriam ter praticamente todas as datas preenchidas; foram encontradas exceções pontuais:

- 14 pedidos delivered sem data de aprovação
- 2 pedidos delivered sem data de envio
- 8 pedidos delivered sem data de entrega
- 6 pedidos canceled com data de entrega preenchida

Conclusão: a análise de valores nulos mostrou que a maior parte das tabelas apresenta alta completude. Os principais pontos de atenção foram identificados em **products**, **order_reviews** e **orders**.

Em **products**, foram identificados 610 registros sem informações de categoria e atributos descritivos, além de 2 produtos sem informações de peso e dimensões.

Em **order_reviews**, a ausência de títulos e comentários foi considerada esperada, pois esses campos são opcionais e não impedem a utilização da nota da avaliação.

Na tabela **orders**, os valores nulos em determinadas datas estão relacionados principalmente ao status e ao fluxo de processamento dos pedidos.

As demais tabelas não apresentaram valores nulos nos campos analisados. Nenhum registro será excluído nesta etapa, pois os valores ausentes devem ser interpretados de acordo com o contexto de negócio antes de qualquer tratamento.

3.4 Etapa 4 — Integridade Referencial

Objetivo: verificar se os relacionamentos entre as tabelas estão corretos, identificando registros “órfãos”. Com isso, a etapa de Data Validation conclui a verificação de carga, completude, unicidade e integridade referencial antes das validações de consistência de negócio.

Padrão de verificação aplicado a cada relação (exemplo **orders** → **customers**):

```
SELECT COUNT(*) AS pedidos_sem_cliente
FROM orders o
LEFT JOIN customers c ON o.customer_id = c.customer_id
WHERE c.customer_id IS NULL;
```

Relação	Verificação	Órfãos
orders → customers	pedidos com cliente inexistente	0
order_items → orders	itens com pedido inexistente	0
order_items → products	itens com produto inexistente	0
order_items → sellers	itens com vendedor inexistente	0
order_payments → orders	pagamentos com pedido inexistente	0
order_reviews → orders	avaliações com pedido inexistente	0
products → category_translation	categorias sem tradução	13

Entre os produtos que possuem categoria preenchida, foi verificado se todas as categorias têm tradução correspondente:

```
SELECT p.product_category_name AS categoria, COUNT(*) AS quantidade_produtos
FROM products p
LEFT JOIN category_translation ct
  ON p.product_category_name = ct.product_category_name
WHERE p.product_category_name IS NOT NULL
  AND ct.product_category_name IS NULL
GROUP BY p.product_category_name
ORDER BY quantidade_produtos DESC;
```

Categoria sem tradução	Produtos afetados
portateis_cozinha_e_preparadores_de_alimentos	10
pc_gamer	3

Conclusão: a análise de integridade referencial não identificou registros órfãos nas principais relações entre pedidos, clientes, itens, produtos, vendedores, pagamentos e avaliações. Todas as referências analisadas possuem correspondência nas respectivas tabelas relacionadas, indicando boa consistência entre as entidades do dataset.

A única exceção foi identificada na relação entre **products** e **category_translation**, onde 13 produtos pertencentes a 2 categorias não possuem correspondência na tabela de tradução, essa inconsistência afeta apenas a tradução das categorias para o inglês e não compromete a existência ou utilização dos produtos nas análises.

4. Data Quality

Nesta etapa, foram realizadas verificações de consistência lógica e de negócio com o objetivo de avaliar se os dados, além de completos e estruturalmente válidos, apresentam relações coerentes entre valores, status, datas e entidades. As inconsistências identificadas foram quantificadas e investigadas antes da definição de qualquer tratamento ou exclusão. *As verificações contemplam principalmente as dimensões de consistência e validade de negócio dos dados.*

O script completo das validações: [sql/03_data_quality.sql](#)

O processo de verificação seguiu um checklist com oito regras:

Regra	Nome	Descrição
1	Sequência Cronológica dos Pedidos	Verifica se as datas do pedido seguem a ordem lógica compra → aprovação → envio → entrega.
2	Coerência entre Status e Datas	Verifica se o status registrado é compatível com as datas já preenchidas do pedido.
3	Consistência dos Valores Financeiros	Verifica se preço, frete, pagamento e parcelas apresentam valores válidos (sem zeros ou negativos indevidos).
4	Consistência das Avaliações	Verifica se as notas de avaliação (review_score) estão dentro da escala esperada de 1 a 5.
5	Atributos Físicos dos Produtos	Verifica se peso e dimensões dos produtos possuem valores coerentes (sem zeros ou extremos).
6	Consistência dos Status dos Pedidos	Verifica se o campo order_status contém apenas valores válidos e analisa sua distribuição no dataset.
7	Coerência entre Pedido e Pagamento	Verifica se o total pago em cada pedido é compatível com a soma de itens e frete.
8	Consistência Geográfica	Verifica se os campos de estado (UF) de clientes e vendedores usam siglas válidas.

Regra 1 — Sequência Cronológica dos Pedidos

Objetivo: verificar se as datas do pedido seguem a sequência lógica Compra → Aprovação → Envio → Entrega, identificando casos em que uma etapa ocorre antes de uma etapa que deveria precedê-la (quando as datas existem — nem todo pedido passa por todas as etapas).

```
SELECT COUNT(*) AS pedidos_com_datas_inconsistentes
FROM orders
WHERE (order_approved_at IS NOT NULL AND order_approved_at < order_purchase_timestamp)
      OR (order_delivered_carrier_date IS NOT NULL AND order_delivered_carrier_date <
order_purchase_timestamp)
      OR (order_delivered_customer_date IS NOT NULL AND order_delivered_customer_date <
order_purchase_timestamp)
      OR (order_delivered_customer_date IS NOT NULL AND order_delivered_carrier_date IS
NOT NULL
      AND order_delivered_customer_date < order_delivered_carrier_date);
```

Sub-regra	Validação	Resultado principal	Status
1.1	Aprovação anterior à compra	0 pedidos	OK
1.2	Envio anterior à compra	166 pedidos: 164 (98,8%) com diferença < 24h 2 casos mais significativos	ATENÇÃO
1.3	Entrega anterior à compra	0 pedidos	OK
1.4	Entrega anterior ao envio	23 pedidos; 16 (69,6%) com diferença > 24h	ATENÇÃO

Conclusão: a validação da sequência cronológica identificou 189 pedidos com inconsistências temporais entre as etapas de compra, envio e entrega. Foram encontrados 166 pedidos com data de envio à transportadora anterior à data da compra, sendo que 164 desses casos apresentam diferença inferior a 24 horas e apenas 2 possuem divergências mais significativas.

Também foram identificados 23 pedidos com data de entrega ao cliente anterior à data de envio, dos quais 16 apresentam diferença superior a 24 horas.

Não foram encontrados casos de aprovação ou entrega ao cliente anteriores à compra. Como a causa dessas divergências não pode ser determinada apenas com as informações disponíveis no dataset, os registros serão mantidos. Na camada analítica, cada caso deve ser excluído apenas de KPIs que dependam diretamente do par de timestamps ou da etapa do ciclo afetada; registros podem permanecer em métricas baseadas em pares de datas cuja cronologia relevante seja válida.

Regra 2 — Coerência entre Status do Pedido e Datas

Objetivo: verificar se o status registrado é coerente com as etapas já ocorridas, por exemplo, um pedido **delivered** deveria ter **order_delivered_customer_date** preenchida, e um pedido **canceled** normalmente não deveria ter entrega concluída.

```
SELECT COUNT(*) AS total_delivered,
       COUNT(*) FILTER (WHERE order_delivered_customer_date IS NULL) AS
sem_data_entrega
FROM orders
WHERE order_status = 'delivered';
```

Sub-regra	Validação	Resultado principal	Status
2.1	delivered sem data de entrega (order_delivered_customer_date)	8 de 96.478 (0,008%)	ATENÇÃO
2.2	canceled com data de entrega (order_delivered_customer_date)	6 de 625 (0,960%); todos com sequência completa	ATENÇÃO
2.3	delivered sem aprovação, envio ou entrega ausentes	23 pedidos únicos: 14 sem data aprovação, 2 sem data envio, 8 sem data entrega (1 sobreposição)	ATENÇÃO

Conclusão: a análise de coerência entre o status dos pedidos e as datas do processo identificou um número reduzido de inconsistências, 8 dos 96.478 pedidos delivered (0,008%) não têm data de entrega, uma contradição lógica, ainda que estatisticamente irrelevante, também foram encontrados 6 dos 625 pedidos canceled (0,96%) com data de entrega registrada, todos com sequência cronológica completa (compra → aprovação → envio → entrega), indicando uma divergência entre o status final registrado e as datas do processo. Também foram identificados 23 dos 96.478 pedidos com pelo menos uma data ausente nas etapas de aprovação, envio ou entrega.

As divergências são pequenas em volume, sem impacto relevante sobre o dataset como um todo e como o dataset não fornece informações adicionais que permitam determinar a causa dessas divergências, os registros serão mantidos, porém deverão ser considerados com cautela em análises que dependam do status do pedido ou das datas específicas do processo logístico.

Regra 3 — Consistência dos Valores Financeiros

Objetivo: verificar se preço, frete, pagamento e número de parcelas apresentam valores válidos, identificando zeros, negativos ou combinações que possam comprometer análises financeiras.

```
SELECT COUNT(*) AS total_itens,
       COUNT(*) FILTER (WHERE price <= 0) AS preco_invalido,
       MIN(price) AS menor_preco, MAX(price) AS maior_preco
FROM order_items;
```

Sub-regra	Validação	Resultado principal	Status
3.1	Preço zero ou negativo	112.650 itens: 0 zeros, 0 negativos, Valores de R\$ 0,85 a R\$ 6.735,00	OK
3.2	Frete zero ou negativo	383 fretes zero (0,34%) 0 negativos Valores de R\$ 0,00 a R\$ 409,68	OK (observação)
3.3	Pagamento zero ou negativo	9 pagamentos zero em 8 pedidos: contextualizados (not_defined / voucher) 0 negativos	OK (observação)
3.4	Parcelas zero ou negativas	2 pagamentos com 0 parcelas (credit_card), ambos associados a payment_sequential = 2	ATENÇÃO

Conclusão: a análise mostrou que os dados apresentam boa consistência financeira geral. Não foram identificados preços, fretes ou pagamentos negativos, e todos os 112.650 itens possuem preços superiores a zero. Foram encontrados 383 itens com frete igual a zero e 9 registros de pagamento com valor igual a zero. Foram identificados 2 registros de pagamento via cartão de crédito com **payment_installments = 0**, ambos associados a **payment_sequential = 2**. Como o dataset não fornece informações suficientes para determinar a causa dessa ocorrência, os registros foram mantidos e classificados como inconsistências pontuais. Os registros com **payment_type = 'not_defined'** e pagamentos de valor zero foram mantidos, pois não há evidência suficiente no dataset para classificá-los como erros. Esses casos deverão ser considerados separadamente quando relevantes para a análise.

Regra 4 — Consistência das Avaliações

Objetivo: verificar se as notas de avaliação (**review_score**) estão dentro da escala esperada de 1 a 5, e conferir a distribuição das notas.

```
SELECT review_score, COUNT(*) AS quantidade,
       ROUND(100.0 * COUNT(*) / SUM(COUNT(*)) OVER (), 2) AS percentual
FROM order_reviews
GROUP BY review_score
ORDER BY review_score;
```

Sub-regra	Validação	Resultado principal	Status
4.1	Notas fora da escala 1–5	99.224 avaliações; mínimo 1, máximo 5; 0 inválidas	OK
4.2	Distribuição das notas	Todas as notas de 1 a 5 representadas; percentuais somam 100%	OK

Conclusão: nenhuma inconsistência identificada. O campo **review_score** pode ser usado diretamente em análises de satisfação, sem tratamento adicional. Nenhuma nota fora do intervalo 1–5. A distribuição mostra forte concentração em notas altas: 57,78% das 99.224 avaliações são nota 5, e 19,29% são nota 4 — ou seja, quase 77% das avaliações são positivas.

Regra 5 — Atributos Físicos dos Produtos

Objetivo: verificar se peso, comprimento, altura e largura dos produtos apresentam valores coerentes, identificando zeros, negativos ou extremos que possam comprometer análises logísticas.

```
SELECT product_id, product_category_name, product_weight_g,
       product_length_cm, product_height_cm, product_width_cm
FROM products
WHERE product_weight_g <= 0
ORDER BY product_id;
```

Sub-regra	Validação	Resultado principal	Status
5.1	Peso e dimensões ≤ 0	4 produtos com peso = 0g; nenhum comprimento/altura/largura ≤ 0	ATENÇÃO
5.2	Valores físicos extremos	Peso máx. 40,425 kg; comprimento e altura máx. 105 cm; largura máx. 118 cm	OK

Conclusão: a análise dos atributos físicos dos 32.951 produtos identificou 4 (0,012% de 32.951) têm peso = 0g, todos da categoria **cama_mesa_banho**, todos com as mesmas dimensões (30×25×30 cm), indicando uma inconsistência pontual no atributo de peso, não um problema sistêmico. Nenhum valor negativo foi encontrado em nenhum atributo físico. O maior peso registrado é 40,425 kg e a maior dimensão é 118 cm. Os valores máximos foram inspecionados e, com base apenas na magnitude observada, não foram classificados como inconsistências. Os quatro produtos com peso zero serão mantidos, mas deverão ser tratados com cautela em análises que utilizem peso.

Regra 6 — Consistência dos Status dos Pedidos

Objetivo: verificar se **order_status** apresenta apenas valores válidos e coerentes, identificando valores inesperados e analisando a distribuição das categorias existentes.

```
SELECT order_status, COUNT(*) AS quantidade,
       ROUND(100.0 * COUNT(*) / SUM(COUNT(*) OVER ()), 2) AS percentual
FROM orders
GROUP BY order_status
ORDER BY quantidade DESC;
```

Status	Quantidade	Percentual
delivered	96.478	97,02%
shipped	1.107	1,11%
canceled	625	0,63%
unavailable	609	0,61%
invoiced	314	0,32%
processing	301	0,30%
created	5	0,01%
approved	2	0,00%

Sub-regra	Validação	Resultado principal	Status
6.1	Valores existentes e distribuição de order_status	8 status distintos; nenhum nulo/anômalo; delivered = 97,02%	OK

Conclusão: a análise dos status dos pedidos não identificou inconsistências estruturais no campo **order_status**. Os 99.441 pedidos estão distribuídos entre 8 categorias distintas, sem valores nulos ou categorias aparentemente inválidas. A maior parte dos registros possui status **delivered**, representando 97,02% dos pedidos. A predominância de delivered caracteriza a distribuição deste dataset e não representa, por si só, uma inconsistência. As divergências entre status e datas foram avaliadas separadamente na Regra 2.

Regra 7 — Coerência entre Valor do Pedido e Pagamentos

Objetivo: verificar se o total pago em cada pedido é coerente com a soma de preços e fretes dos itens, com tolerância de R\$ 0,01 para diferenças de arredondamento.

Observação: um pedido pode ter vários registros em **order_items** e vários em **order_payments**. Um JOIN direto entre as duas tabelas multiplicaria linhas (fan-out) e inflaria os SUM(). Por isso, o total de cada pedido foi calculado separadamente em cada tabela antes da comparação:

```
WITH item_totals AS (
    SELECT order_id, SUM(price + freight_value) AS valor_pedido
    FROM order_items GROUP BY order_id
),
payment_totals AS (
    SELECT order_id, SUM(payment_value) AS valor_pago
    FROM order_payments GROUP BY order_id
)
SELECT COUNT(*) AS pedidos_comparados,
       COUNT(*) FILTER (WHERE ABS(i.valor_pedido - p.valor_pago) <= 0.01) AS
valores_iguais,
       COUNT(*) FILTER (WHERE ABS(i.valor_pedido - p.valor_pago) > 0.01) AS
valores_divergentes
FROM item_totals i
JOIN payment_totals p ON i.order_id = p.order_id;
```

Sub-regra	Validação	Resultado principal	Status
7.1	Produtos + frete vs. pagamentos	98.665 comparados: 98.362 compatíveis (99,69%); 303 divergentes (0,31%) > R\$ 0,01	ATENÇÃO
7.2	Magnitude das 303 divergências	54 até R\$ 1,00; 151 entre R\$ 1,01–10; 90 entre R\$ 10,01–50; 8 acima de R\$ 50	ATENÇÃO
7.3	Investigação dos 8 casos > R\$ 50	Maior diferença R\$ 182,81; 7 pagamentos acima do valor calculado, 1 abaixo; todos delivered	ATENÇÃO
7.4	Composição dos pagamentos dos 8 casos	Todos via credit_card, 1 registro por pedido, parcelamento de 5 a 24 vezes	ATENÇÃO
7.5	Pedidos fora do INNER JOIN	776 pedidos: 775 sem itens + 1 sem pagamento, sem sobreposição	Informativo
7.6	Status dos 775 pedidos sem itens	767 (98,97%) unavailable ou canceled; 1 shipped sem itens	ATENÇÃO
7.7	Único pedido sem order_payments	1 pedido delivered sem nenhum registro de pagamento	ATENÇÃO

Conclusão: a análise mostrou elevada consistência geral. Entre 98.665 pedidos que possuem informações de itens e pagamentos, 98.362 (aproximadamente 99,69%) apresentam diferença de até R\$ 0,01 entre a soma dos produtos e frete e o valor total registrado nos pagamentos.

Foram identificados 303 pedidos (aproximadamente 0,31%) com divergências superiores a R\$ 0,01, e os 8 casos acima de R\$ 50 foram investigados individualmente: todos possuem um único registro de pagamento via cartão de crédito, com parcelamento entre 5 e 24 vezes, 7 com pagamento acima do valor calculado.

Os 776 pedidos fora da comparação (775 sem itens + 1 sem pagamento) foram auditados à parte e 98,97% dos sem itens estão em status **unavailable** ou **canceled**, o que é coerente com o fluxo. Ainda assim, o dataset não fornece informações suficientes para determinar a causa exata das divergências; os registros serão mantidos, mas deverão ser tratados com cautela em análises financeiras que dependam diretamente desses valores.

Regra 8 — Consistência Geográfica

Objetivo: verificar se os campos de estado (UF) de clientes e vendedores usam exclusivamente siglas válidas das unidades federativas brasileiras, evitando categorias incorretas que comprometam análises regionais no Power BI.

```
SELECT customer_state, COUNT(*) AS quantidade
FROM customers
GROUP BY customer_state
ORDER BY customer_state;
```

Sub-regra	Validação	Resultado principal	Status
8.1	Estados dos clientes (customer_state)	27 UFs, todas válidas e padronizadas	OK
8.2	Estados dos vendedores (seller_state)	23 UFs, todas válidas e padronizadas	OK

Conclusão: os campos **customer_state** e **seller_state** podem ser usados diretamente em visualizações de mapa e análises regionais no Power BI, sem necessidade de padronização adicional. Clientes presentes nas 27 UFs brasileiras (nenhuma sigla inválida). Vendedores presentes em 23 das 27 UFs — a ausência nas 4 restantes é uma característica da distribuição dos dados, não uma inconsistência.

5. Resumo Consolidado

Esta seção consolida, em duas tabelas, todo o processo de Data Validation e Data Quality descrito nas seções 3 e 4: primeiro uma visão das 4 etapas executadas (Volume, Duplicidades, Valores Nulos, Integridade Referencial) e, em seguida, o detalhamento das 8 regras de consistência de dados aplicadas na última etapa.

Resumo das 4 Etapas de Data Validation

Etapa	Nome	Objetivo	Resultado principal	Status
1	Volume	Confirmar a carga correta das 9 tabelas no PostgreSQL	100% das tabelas carregadas; mais de 1,5 milhão de registros no total	OK
2	Duplicidades	Garantir que a chave única de cada tabela não está repetida	0 duplicidades nas 8 tabelas com chave definida; geolocation com ocorrências múltiplas esperadas	OK (observação)
3	Valores Nulos	Identificar campos com NULL e avaliar se são esperados	Nulos concentrados em campos opcionais (products, order_reviews) e no fluxo natural de status de orders	OK (observação)
4	Integridade Referencial	Identificar registros órfãos entre tabelas relacionadas	0 órfãos nas relações principais; 13 produtos (2 categorias) sem tradução	OK (observação)

Em números: 100% das tabelas carregadas corretamente, 0 duplicidades nas 8 tabelas com chave definida e 0 registros órfãos nas relações principais — a única exceção é a ausência de tradução em 13 produtos (2 categorias).

Resumo das 8 Regras de Data Quality

Regras	Validação	Resultado principal	Status
1	Sequência cronológica	189 pedidos com inconsistências temporais	ATENÇÃO
2	Status × datas	Pequeno número de divergências entre status e etapas do pedido	ATENÇÃO
3	Valores financeiros	Valores majoritariamente válidos; poucas exceções em pagamentos	ATENÇÃO
4	Avaliações	Notas válidas entre 1 e 5	OK
5	Atributos dos produtos	4 produtos com peso zero	ATENÇÃO
6	Status dos pedidos	8 status válidos e padronizados	OK
7	Pedido × pagamento	99,69% dos pedidos comparáveis financeiramente consistentes	ATENÇÃO
8	Dados geográficos	Estados válidos e padronizados	OK

Em números: 99,69% dos pedidos comparáveis são financeiramente consistentes, 189 pedidos apresentam inconsistência cronológica (Regra 1) e apenas 4 produtos têm peso zerado (Regra 5) — as demais regras (4, 6 e 8) não identificaram nenhuma inconsistência.

Conclusão geral: o processo de Data Validation e Data Quality aplicado ao dataset da Olist confirmou uma base de boa qualidade geral. Das 4 etapas de Data Validation, a etapa de Volume não apresentou inconsistências, enquanto Duplicidades, Valores Nulos e Integridade Referencial apresentaram apenas observações pontuais, sem impacto relevante. Das 8 regras de Data Quality, 3 não identificaram nenhuma inconsistência (Avaliações, Status dos Pedidos e Consistência Geográfica) e as demais 5 apresentaram exceções pontuais, bem delimitadas e documentadas — nenhuma delas capaz de comprometer a análise como um todo, com destaque para a consistência financeira de 99,69% entre pedidos e pagamentos. Nenhum registro foi excluído nesta fase; a decisão de manter, filtrar ou sinalizar cada caso foi documentada para a camada de modelagem (Power BI), preservando a rastreabilidade dos dados originais.

6. Guia de Tratamento para Modelagem

Esta seção é a referência rápida para a camada analítica e para o Power BI: reúne, em um só lugar, o tratamento definido para cada inconsistência encontrada nas seções 3 e 4, conforme a pergunta de negócio e o KPI analisado.

Situação	Onde está a análise	Decisão
Dados brutos	<i>Princípio geral (Seções 3 e 4)</i>	Preservar sem alterações destrutivas
geolocation duplicada	<i>Seção 3.2 — Etapa 2 (Duplicidades)</i>	Criar versão analítica/deduplicada apenas se necessária
Produtos sem categoria	<i>Seção 3.3 — Etapa 3 (Valores Nulos)</i>	Manter; tratar como não informado em análises por categoria
Datas inconsistentes/ausentes	<i>Seção 3.3 — Etapa 3 (Valores Nulos)</i>	Excluir apenas de KPIs que dependam da respectiva data
Categorias sem tradução	<i>Seção 3.4 — Etapa 4 (Integridade Referencial)</i>	Manter categoria original ou mapear manualmente apenas na camada analítica
Sequência cronológica inconsistente (189 pedidos)	<i>Seção 4 — Regra 1</i>	Manter; sinalizar e excluir apenas de KPIs que dependam diretamente do par de timestamps ou etapa do ciclo afetada
Status × datas incoerentes (29 pedidos únicos)	<i>Seção 4 — Regra 2</i>	Manter; excluir de métricas de lead time que dependam dessas datas
Parcelamento zerado (2 pagamentos)	<i>Seção 4 — Regra 3</i>	Manter; tratar como caso pontual, sem impacto relevante
Peso zero	<i>Seção 4 — Regra 5</i>	Desconsiderar em análises específicas de peso
Pagamentos divergentes	<i>Seção 4 — Regra 7</i>	Manter e sinalizar; não inferir causa sem evidência
Pedidos sem itens ou sem pagamento (776 pedidos)	<i>Seção 4 — Regra 7</i>	Excluir de métricas financeiras que dependam simultaneamente de itens e pagamentos

Princípio adotado: uma anomalia pequena não é automaticamente removida. A decisão depende do impacto sobre a pergunta de negócio e o KPI analisado. *Nem todas as decisões acima têm efeito direto nos indicadores exibidos no dashboard atual (Seção 8).*

7. Business Analysis

Com as etapas de Data Validation e Data Quality concluídas, a análise avançou para a definição de regras de negócio, KPIs e perguntas analíticas. O objetivo desta etapa foi transformar os dados validados em indicadores capazes de explicar desempenho comercial, comportamento dos clientes, categorias de produtos, distribuição geográfica, logística e satisfação. Antes do cálculo dos indicadores, foram definidas regras de negócio para garantir consistência entre as análises e evitar interpretações diferentes para a mesma métrica.

Regra	Definição adotada
Pedidos concluídos	order_status = 'delivered' para análises comerciais concluídas
Product GMV	Soma de order_items.price; não inclui frete e não representa receita líquida da Olist
Total Order Value	Soma de price + freight_value por pedido
AOV	Média do Total Order Value após agregação no nível de order_id
Clientes únicos	customer_unique_id, evitando contar o mesmo cliente mais de uma vez
On-Time Delivery	Entrega na mesma data ou antes de order_estimated_delivery_date, comparando DATE
Reviews múltiplos	Agregados previamente no nível de order_id para evitar peso duplicado
Janela principal de tendência	Jan/2017 a Ago/2018 para evitar períodos residuais/incompletos nas comparações
Ranking de preço médio	Exige volume mínimo de 50 itens vendidos por categoria, para reduzir distorção de categorias com poucas vendas

O script completo desta etapa está disponível em: [sql/04_business_analysis.sql](#)

7.1 Visão geral comercial e comportamento de compra

Dos 99.441 pedidos do dataset, 96.478 (97,02%) possuem status delivered. Para manter coerência com vendas concluídas, essa população foi utilizada como base principal das métricas comerciais.

```
WITH order_values AS (
  SELECT oi.order_id,
         SUM(oi.price + oi.freight_value) AS order_value
  FROM order_items oi
  JOIN orders o ON oi.order_id = o.order_id
  WHERE o.order_status = 'delivered'
  GROUP BY oi.order_id
)
SELECT COUNT(*) AS delivered_orders,
       ROUND(AVG(order_value), 2) AS average_order_value
FROM order_values;
```

Indicador	Resultado	Leitura
Clientes únicos com pedidos entregues	93.358	Base de clientes utilizada nas análises comerciais
Clientes recorrentes	2.801	Clientes com mais de um pedido delivered
Repeat Customer Rate	3,00%	Baixa frequência de recompra dentro do período observado
AOV	R\$ 159,83	Valor médio do pedido incluindo frete
Mediana do pedido	R\$ 105,28	A distribuição é assimétrica e puxada por pedidos de maior valor
Pedidos com 1 item	90,01%	Cestas predominantemente pequenas
Pedidos com até 2 itens	97,67%	A maior parte das compras possui um ou dois itens

Conclusão: a baixa recorrência observada e a predominância de pedidos com poucos itens indicam que, dentro da janela disponível, o crescimento observado está mais associado ao aumento do volume de pedidos e ao valor unitário dos produtos do que a grandes cestas ou alta frequência de recompra.

7.2 Tendências de vendas

A evolução mensal foi analisada pela data de compra (**order_purchase_timestamp**). Para comparações consistentes entre anos, foi utilizada a janela equivalente de janeiro a agosto de 2017 e de 2018.

Métrica	Jan-Ago/2017	Jan-Ago/2018	Variação YoY
Delivered Orders	21.998	52.783	+139,94%
Total Order Value	R\$ 3.472.898,25	R\$ 8.451.584,77	+143,36%
AOV	R\$ 157,87	R\$ 160,12	+1,42%

Conclusão: o forte crescimento observado em 2018 foi impulsionado principalmente pelo aumento do volume de pedidos. O AOV permaneceu praticamente estável, crescendo apenas 1,42% entre os períodos comparáveis.

Em novembro de 2017 foi observado um pico relevante: +62,77% em pedidos e +53,55% em Total Order Value em relação a outubro. Como o dataset não contém informação causal sobre campanhas ou eventos comerciais, o pico foi registrado sem atribuição de causa.

Os primeiros meses de 2017 possuem base menor; por isso, percentuais YoY muito altos no início de 2018 devem ser interpretados com efeito de base baixa.

7.3 Produtos e categorias

A análise de categorias utilizou **LEFT JOIN** com **category_translation** e **COALESCE** para preservar produtos sem tradução ou sem categoria. Dessa forma, nenhum produto é perdido silenciosamente por ausência de mapeamento.

```
SELECT
    COALESCE(ct.product_category_name_english,
             p.product_category_name,
             'unknown') AS category,
    COUNT(*) AS items_sold,
    ROUND(SUM(oi.price), 2) AS product_gmv
FROM order_items oi
JOIN orders o ON oi.order_id = o.order_id
JOIN products p ON oi.product_id = p.product_id
LEFT JOIN category_translation ct
    ON p.product_category_name = ct.product_category_name
WHERE o.order_status = 'delivered'
GROUP BY 1
ORDER BY product_gmv DESC;
```

Categoria	Itens vendidos	Product GMV	Share GMV	Preço médio/item
health_beauty	9.465	R\$ 1.233.131,72	9,33%	R\$ 130,28
watches_gifts	5.859	R\$ 1.166.176,98	8,82%	R\$ 199,04
bed_bath_table	10.953	R\$ 1.023.434,76	7,74%	R\$ 93,44
sports_leisure	8.431	R\$ 954.852,55	7,22%	R\$ 113,25
computers_accessories	7.644	R\$ 888.724,61	6,72%	R\$ 116,26

Conclusão: **health_beauty** lidera Product GMV, enquanto **bed_bath_table** lidera em volume de itens. **Watches & Gifts** aparece apenas em 7º lugar por volume, mas em 2º por GMV, refletindo o maior preço médio por item. As 5 maiores categorias representam 39,83% do Product GMV; são necessárias 18 categorias para ultrapassar 80%, atingindo 81,29%. Isso indica concentração moderada e participação relevante de diversos segmentos. Produtos sem categoria representam 584 produtos vendidos, 1.537 itens, 1.392 pedidos e R\$ 170.726,63 de Product GMV (1,29%). Esses registros foram mantidos e agrupados como unknown nas análises por categoria.

7.4 Clientes e distribuição geográfica

A distribuição geográfica foi analisada pelo estado do cliente. Foi validado que 93.321 dos 93.358 clientes únicos com pedidos entregues (99,96%) aparecem vinculados a apenas um estado; somente 37 aparecem em mais de um estado.

Estado	Delivered Orders	Share pedidos	Product GMV	Share GMV	AOV
SP	40.501	41,98%	R\$ 5.067.633,16	38,33%	R\$ 142,46
RJ	12.350	12,80%	R\$ 1.759.651,13	13,31%	R\$ 166,43
MG	11.354	11,77%	R\$ 1.552.481,83	11,74%	R\$ 160,20
RS	5.345	5,54%	R\$ 728.897,47	5,51%	R\$ 161,17
PR	4.923	5,10%	R\$ 666.063,51	5,04%	R\$ 158,79

SP concentra 41,98% dos pedidos entregues e 38,33% do Product GMV. SP, RJ e MG juntos representam 66,55% dos pedidos e 63,38% do GMV, mostrando forte concentração comercial no Sudeste.

A decomposição do AOV mostrou que diferenças regionais são explicadas tanto pelo valor dos produtos quanto pelo frete. SP possui o menor AOV estadual (R\$ 142,46) e também a menor participação de frete no valor total (12,17%). Em vários estados de menor volume, os valores médios de produto e frete são superiores.

Como 37 **customer_unique_id** aparecem em mais de um estado, contagens de clientes por UF não devem ser somadas como total aditivo. Para KPIs geográficos aditivos, pedidos e GMV são preferidos.

7.5 Logística e cumprimento de prazo

A análise logística utiliza apenas pedidos delivered com **order_delivered_customer_date** preenchida. Os 8 pedidos delivered sem data de entrega são excluídos somente das métricas que dependem diretamente desse campo. A regra de pontualidade foi definida no nível de data: um pedido é considerado on time quando a data de entrega é igual ou anterior à data estimada. A comparação por timestamp classificaria 1.292 entregas realizadas no próprio dia previsto como atrasadas; por isso, foi adotada a comparação DATE.

Indicador logístico	Resultado
Pedidos analisados	96.470
Average Delivery Time	12,56 dias
Median Delivery Time	10,22 dias
On-Time Orders	89.936
Late Orders	6.534
On-Time Delivery Rate	93,23%
Mediana do atraso	7 dias
P90 do atraso	22 dias
Maior atraso	188 dias

Faixa de atraso	Pedidos atrasados	Percentual
1 a 3 dias	1.870	28,62%
4 a 7 dias	1.802	27,58%
8 a 14 dias	1.478	22,62%
15 a 30 dias	1.039	15,90%
Mais de 30 dias	345	5,28%

Conclusão: 93,23% das entregas analisadas ocorreram dentro do prazo. Entre os pedidos atrasados, 56,20% chegaram em até 7 dias após a data estimada e 78,82% em até 14 dias. Apenas 5,28% dos atrasos ultrapassaram 30 dias.

7.6 Logística e satisfação do cliente

A cobertura de avaliações é alta: 95.832 dos 96.478 pedidos delivered possuem ao menos um review (99,33%). Para os 525 pedidos com múltiplos registros de review, a nota foi agregada previamente no nível de **order_id**, garantindo que cada pedido tenha o mesmo peso analítico.

Status	Pedidos com review	Review médio	Reviews baixos (≤ 2)	Reviews positivos (≥ 4)
On time	89.443	4,29	9,23%	82,64%
Late	6.381	2,27	62,36%	26,74%

A diferença é expressiva: pedidos no prazo apresentam review médio de 4,29, enquanto pedidos atrasados registram 2,27. Reviews baixos aparecem em 62,36% dos atrasados contra 9,23% dos pedidos no prazo.

Faixa	Pedidos	Review médio	Reviews baixos (≤ 2)	Reviews positivos (≥ 4)
On time	89.443	4,29	9,23%	82,64%
1–3 dias	1.852	3,29	32,18%	53,24%
4–7 dias	1.748	2,11	67,56%	22,48%
8–14 dias	1.446	1,67	80,08%	11,07%
15–30 dias	1.006	1,62	81,61%	9,05%
>30 dias	329	2,06	67,78%	23,10%

Conclusão: há forte associação negativa entre atraso e satisfação. A deterioração é acentuada já nos primeiros dias de atraso e permanece forte até 30 dias. A cauda acima de 30 dias é menor e heterogênea; portanto, não foi utilizada para inferir uma relação estritamente linear entre duração do atraso e nota.

Esta análise demonstra associação, não causalidade. Review score também pode refletir qualidade do produto, atendimento, vendedor e outros fatores não isolados no dataset.

7.7 Principais insights de negócio

- O crescimento observado em 2018 foi principalmente volume-driven: pedidos +139,94% e Total Order Value +143,36% entre Jan-Ago/2017 e Jan-Ago/2018, enquanto o AOV cresceu apenas 1,42%.
- A recorrência é baixa dentro da janela observada: somente 3,00% dos clientes com pedidos entregues fizeram mais de uma compra.
- As cestas são pequenas: 90,01% dos pedidos possuem apenas um item e 97,67% possuem no máximo dois.
- Volume e valor contam histórias diferentes por categoria: bed_bath_table lidera em itens, enquanto health_beauty lidera Product GMV.
- A operação é geograficamente concentrada: SP responde por 41,98% dos pedidos entregues; SP, RJ e MG somam 66,55%.
- O desempenho logístico está fortemente associado à satisfação: review médio 4,29 no prazo versus 2,27 em atraso.

8. Dashboard no Power BI

Com as etapas de Data Validation, Data Quality e Business Analysis concluídas, os dados foram levados ao Power BI para modelagem analítica, criação das medidas DAX e construção do dashboard final. O objetivo foi transformar os resultados validados em uma camada visual orientada a perguntas de negócio, preservando as mesmas definições e regras adotadas nas consultas SQL.

Dashboard: [dashboard/Olist_Ecommerce_Analytics.pbix](#)

8.1 Modelagem analítica e critérios de cálculo

A preparação no Power BI foi realizada no Power Query, com separação entre consultas de staging, tabelas fato e dimensões. As medidas foram centralizadas em uma tabela de medidas para facilitar manutenção, leitura e reutilização.

Componente	Papel na camada analítica
fact_orders	Grão de pedido; status, datas, logística, valores agregados e satisfação no nível do pedido.
fact_order_items	Grão de item; volume vendido, preço, produto, vendedor e Product GMV.
fact_reviews	Grão de avaliação; distribuição individual das notas de 1 a 5.
dim_customer / dim_product / dim_seller / dim_date	Dimensões para segmentação de clientes, produtos, vendedores e tempo.
Medidas DAX	KPIs, taxas, médias, rankings e indicadores utilizados nos três painéis.

As regras de negócio definidas na Seção 7 — Product GMV, AOV, pedidos concluídos, janela temporal, On-Time Delivery, agregação de reviews e o volume mínimo de 50 itens no ranking de preço médio — foram preservadas integralmente na camada de Power BI, sem redefinição.

8.2 Estrutura do dashboard

O dashboard final foi organizado em três páginas complementares. A primeira resume o desempenho geral; a segunda aprofunda vendas, categorias e distribuição geográfica; e a terceira relaciona logística e satisfação. Essa organização evita repetição de visuais e mantém uma sequência de leitura do geral para o diagnóstico.

Página do dashboard	Pergunta de negócio	Frentes da Seção 7
1 — Visão Geral	Como o negócio performou?	7.1 Visão geral comercial e comportamento de compra; 7.2 Tendências de vendas
2 — Vendas & Produtos	O que está gerando vendas e valor?	7.3 Produtos e categorias; 7.4 Clientes e distribuição geográfica
3 — Logística & Satisfação	Como a operação de entrega afeta a experiência do cliente?	7.5 Logística e cumprimento de prazo; 7.6 Logística e satisfação do cliente

8.3 Página 1 — Visão Geral

A Visão Geral consolida os principais KPIs e as tendências mensais da janela comparável. Os gráficos mostram que o crescimento foi impulsionado principalmente pelo aumento do volume de pedidos, enquanto o ticket médio permaneceu relativamente estável.




Figura 1 — Dashboard Power BI: Visão Geral.

8.4 Página 2 — Vendas & Produtos

A página detalha volume, valor, preço e concentração comercial. Os visuais comparam categorias por itens vendidos, preço médio e GMV, mostram a relação entre volume e preço e apresentam a concentração geográfica por estado. O ranking de preço médio considera somente categorias com pelo menos 50 itens vendidos.




Figura 2 — Dashboard Power BI: Vendas & Produtos.

8.5 Página 3 — Logística & Satisfação

A página concentra os indicadores de prazo e experiência do cliente. Além de comparar nota média e composição das avaliações entre pedidos no prazo e atrasados, os gráficos mostram a deterioração da satisfação por faixa de atraso e a distribuição das notas individuais.




Figura 3 — Dashboard Power BI: Logística & Satisfação.

8.6 Validação dos KPIs entre SQL e Power BI

Os principais indicadores exibidos no dashboard foram confrontados com os resultados obtidos nas consultas SQL. Essa validação cruzada reduz o risco de diferenças causadas por granularidade, relacionamentos, filtros ou agregações incorretas no modelo.

Indicador	Resultado validado	Uso no dashboard
Total de pedidos	99.441	Visão Geral
Clientes únicos — base completa	96.096	Visão Geral
Clientes únicos — pedidos delivered	93.358	Business Analysis
Pedidos delivered	96.478 (97,02%)	Visão Geral / Logística
Product GMV — delivered	R\$ 13,22 mi	Visão Geral / Vendas & Produtos
AOV — incluindo frete	R\$ 159,83	Visão Geral
Itens vendidos — delivered	110.197	Vendas & Produtos
Categorias com vendas	74	Vendas & Produtos
Média de itens por pedido	1,14	Vendas & Produtos
Participação Top 5 no GMV	39,83%	Vendas & Produtos
Tempo médio de entrega	12,56 dias	Logística & Satisfação
On-Time Delivery Rate	93,23%	Visão Geral / Logística
Review médio — no prazo	4,29	Logística & Satisfação
Review médio — atrasados	2,27	Logística & Satisfação
Cobertura de avaliações	99,33%	Logística & Satisfação

9. Considerações Finais

Este projeto percorreu o ciclo completo de um trabalho de análise de dados: da estruturação do banco em PostgreSQL, passando pelas etapas de Data Validation e Data Quality, até a definição de regras de negócio, KPIs e a construção de um dashboard interativo no Power BI. As etapas foram documentadas de forma independente, mas construídas para se alimentarem entre si: as decisões de tratamento definidas nas Seções 3 e 4 sustentam diretamente os indicadores calculados na Seção 7 e exibidos no dashboard da Seção 8, preservando a rastreabilidade entre o dado bruto e o resultado final.

Mais do que os resultados numéricos, o documento buscou evidenciar um método de trabalho: validar antes de analisar, quantificar antes de decidir e documentar cada tratamento aplicado antes de utilizá-lo na camada analítica — preservando a possibilidade de auditar e revisar qualquer decisão tomada ao longo do processo. O código SQL completo e o arquivo Power BI (.pbix) utilizados neste projeto estão disponíveis no repositório indicado na Seção 1.3.